

Desarrollo de un Sistema de Reconocimiento de Gestos Basado en Inteligencia Artificial para Mejorar el Control de Prótesis Mioeléctricas en Amputados de Miembro Superior

1st Rosales Juarez, Jose Manuel

Facultad de Ciencias e Ingenieria

Universidad Peruana Cayetano Heredia

Lima, Perú

j.rosalesj@pucp.edu.pe

2nd Muñoz Huamán, Nicolle Stephany

Facultad de Ciencias e Ingenieria

Universidad Peruana Cayetano Heredia

Lima, Perú

nicolle.munoz@upch.pe

3rd Rozas Ortiz de Orue, Franco

Facultad de Ciencias e Ingenieria

Universidad Peruana Cayetano Heredia

Lima, Perú

franco.rozas@pucp.edu.pe

4th Tintaya Salva, Jossef Caleb Israel

Facultad de Ciencias e Ingenieria

Universidad Peruana Cayetano Heredia

Lima, Perú

jossef.tintaya@pucp.edu.pe

Abstract—Las amputaciones de miembro superior representan un desafío significativo para la independencia funcional de los pacientes, con proyecciones de 3.2 millones de casos para 2050. Este estudio presenta un enfoque comparativo entre técnicas de aprendizaje automático y aprendizaje profundo para el reconocimiento de gestos en señales electromiográficas de alta densidad, orientado al control de prótesis mioeléctricas. Se implementaron tres modelos: Regresión Logística, Clasificador de Vectores de Soporte Lineal y una Red Neuronal Convolutiva utilizando el dataset público Hyser, que comprende señales electromiográficas de alta densidad de 256 canales con 34 gestos manuales de 20 participantes sanos. Para los modelos de aprendizaje automático se extrajeron características en dominios temporal y frecuencial (valor absoluto medio, media cuadrática, paso por cero, cambios de signo de pendiente, amplitud de Willison, frecuencia media, frecuencia mediana, frecuencia pico), mientras que para aprendizaje profundo se generaron espectrogramas mediante transformada rápida de Fourier de tiempo corto. La optimización de hiperparámetros se realizó mediante búsqueda exhaustiva para Regresión Logística y búsqueda aleatoria para el Clasificador de Vectores de Soporte Lineal, empleando validación cruzada estratificada. Los resultados muestran que la Regresión Logística alcanzó el mejor rendimiento con exactitud de 60.48%, precisión de 60.53%, sensibilidad de 60.73% y puntuación de 60.42%, superando al Clasificador de Vectores de Soporte Lineal (55.59% exactitud) y la Red Neuronal Convolutiva (52.66% exactitud). El análisis de matrices de confusión reveló patrones específicos de clasificación errónea entre gestos similares. Estos hallazgos sugieren que los enfoques de aprendizaje automático tradicional pueden ser más efectivos que el aprendizaje profundo para el reconocimiento de gestos con electromiografía de alta densidad, proporcionando una base sólida para el desarrollo de sistemas de control de prótesis mioeléctricas más precisos y confiables.

Index Terms—prótesis mioeléctricas, reconocimiento de gestos, electromiografía de alta densidad, aprendizaje automático, aprendizaje profundo, señales electromiográficas

I. INTRODUCCIÓN

A nivel mundial, los casos de amputaciones van en aumento y se estima que para el año 2050, la prevalencia alcance los 3.2 millones de personas [1]. La pérdida de alguna sección corporal, limita significativamente la vida de la persona, no solo a nivel funcional, sino también en el ámbito emocional y social. Entre las amputaciones de la extremidad superior, el sitio más común es nivel transhumeral con un 45% de los casos [2]; esto significa que la persona perdió por completo su capacidad de desarrollar tareas que conecten con su entorno, disminuyendo el grado de independencia para realizar sus actividades cotidianas. Es por ello, que el desarrollo de prótesis de miembro superior viene siendo un campo bastante abordado con el fin de brindar una alternativa a los pacientes afectados para mejorar su independencia y restablecer su estilo de vida.

Entre los diferentes tipos de prótesis, las de tipo mioeléctrica pretenden ser la mejor alternativa; en el caso de las mano, principalmente por su capacidad de realizar diversos tipos de agarres funcionales partir de la actividad muscular del paciente, usando sensores de electromiografía de superficie (sEMG) [3]. Esto se logra gracias al reconocimiento de patrones, una herramienta que ayuda a distinguir las señales musculares del usuario para ejecutar movimientos específicos que permite la prótesis [4]. Sin embargo, uno de los principales retos de las prótesis mioeléctricas es la cantidad de movimientos que puedan realizar; debido a que mayores gestos involucran sistemas de control y herramientas de reconocimiento más complejas; lo cual se limita si las señales recopiladas no son suficientes,

Ante ello, una alternativa eficiente es usar la electromiografía de alta densidad (HD-sEMG) una tecnología que

permite una mayor recolección de datos a comparación de las sEMG convencionales, debido a su disposición única de arreglos de electrodos de superficie con múltiples canales para captar señales bioeléctricas con mayor resolución espacial y temporal. Además, su capacidad de mapear la distribución espacial de los potenciales de acción de las unidades motoras, permite analizar patrones de activación muscular con mayor detalle y mejora la fiabilidad del control mioeléctrico [5] [6]

Es por ello que el presente trabajo se centra en plantear modelos de deep learning y machine learning entrenados sobre señales HD-sEMG, con el fin de hacer una evaluación comparativa de ambos enfoques para determinar el modelo más preciso y robusto para su aplicación en el control de prótesis del miembro superior. Para ello, se hace uso de la base de datos de [7], que contiene señales recopiladas con HD-sEMG sobre 34 gestos manuales de 20 participantes sanos. Esta colección está organizada en cinco subconjuntos: (1) pattern recognition (PR), (2) maximal voluntary contraction (MVC), (3) one-degree of freedom (1-DoF), (4) N-DoF y (5) random task, que agrupa contracciones aleatorias sin trayectorias predefinidas. Los datos fueron recopilados haciendo uso de 256 canales y una frecuencia de muestreo de 2048 Hz.

II. METODOLOGÍA

El presente estudio implementa un enfoque comparativo entre técnicas de Machine Learning (ML) y Deep Learning (DL) para el reconocimiento de gestos en señales electromiográficas (EMG), orientado al control de prótesis mioeléctricas. El pipeline a seguir incluye procesos de adquisición de datos, preprocesamiento, extracción de características, entrenamiento de modelos y evaluación comparativa.

A. Dataset

La base de datos empleada para el desarrollo de modelos, denominado Hyser [7], que es de acceso libre. Comprende información adquirida de 20 sujetos, quienes participaron durante 2 sesiones en días separados. Estos sujetos sanos abarcan 12 hombres y 8 mujeres, con edades dentro del rango de 22 a 34 años. La data adquirida contiene 5 subdatasets, los cuales son reconocimiento de patrones (PR) con 34 gestos de mano en total, datos de contracción muscular voluntaria máxima (MVC) y grado de libertad (DoF) durante contracción de cada uno de los dedos, N-DoF datos por combinación de varios dedos, y un dataset de tareas aleatorias.

Hyser dataset fue seleccionado al considerar la poca variabilidad de bases de datos existentes sobre señales electromiográficas de alta densidad, y que comprendan un subdataset para reconocimiento de patrones como "PR" [7]. Para su uso, se adquirieron HD-sEMG de 256 canales con 34 gestos diferentes, donde cada uno -durante las tareas dinámicas- tuvieron un tiempo de duración de 1 segundo para transicionar de estado relajado al gesto requerido. Las señales de interés se adquirieron a una frecuencia de sampleo de 2048 Hz. El almacenamiento de las sesiones de cada sujeto se nombraron en 40 folders, con nomenclatura "subjecti_sessionj", donde $i \in '01', '02', \dots, '20'$ representa el índice del sujeto y $j \in '1', '2'$

representa el índice de sesión. Adicionalmente, las etiquetas de gestos verdaderas se almacenaron en archivos .txt con formato de valores separados por comas.

B. Preprocesamiento de señales

Para transformar los datos crudos en una entrada adecuada y de alta calidad, se plantearon distintos procesos de preprocesamiento. Para ello, se realizó una normalización de amplitudes de señales con z-score para reducir la variabilidad entre sujetos y sesiones, de forma que se generalicen los modelos, obteniendo media 0 y desviación estándar 1 luego de la transformación de los datos [8]. Posteriormente, analizando el comportamiento de los datos adquiridos que duran 1 segundo para tareas dinámicas, el paso entre estado relajado a dinámico conlleva un tiempo perdido en el que no se realiza algún cambio significativo, por lo cual se recortaron los 0.5 segundos iniciales de las señales para trabajar con las de interés.

C. Métodos

a) *Extracción de características para ML*: El proceso de extracción exploró características en el dominio del tiempo (MAV, RMS, ZC, SSC, WAMP) y en la frecuencia (MNF, MDF, PKF), las cuales son destacadas en la literatura [9]. Los conceptos de cada característica se encuentran de la siguiente manera:

- **Valor Absoluto Medio (MAV)**: Representa el valor absoluto de la señal EMG en una sección de tiempo, donde se produce un gran aumento de su valor inicialmente y durante la contracción [10]. La ecuación (1) expresa:

$$MAV = \frac{1}{N} \sum_{i=1}^N |xi| \quad (1)$$

,donde xi son los datos EMG y N es el número de muestras en cada ventana temporal.

- **Media Cuadrática (RMS)**: Refiere a la raíz cuadrada de la potencia media de la señal EMG para una sección o periodo de tiempo determinado [11]. La ecuación (2) expresa:

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N xi^2} \quad (2)$$

- **Paso por Cero (ZC)**: Cuenta la cantidad de veces que la señal cambia el signo en su amplitud a lo largo del tiempo. La ecuación (3) calcula:

$$ZC = \sum_{i=1}^N sgn(-xi xi_{-1}) \quad (3)$$

$$sgn(x) = \begin{cases} 1, & \text{if } x > 0 \\ 0, & \text{otherwise} \end{cases}$$

- **Cambios de signo de pendiente (SSC)**: Contabiliza la cantidad de veces que la pendiente de la señal EMG cambia de signo en un tiempo determinado. La ecuación (4) la define como:

$$SSC = \sum_{i=2}^{N-1} f[(x_i - x_{i-1}) * (x_i - x_{i+1})] \quad (4)$$

$$f(x) = \begin{cases} 1, & \text{if } x > \text{threshold} \\ 0, & \text{otherwise} \end{cases}$$

, donde el umbral definido fue de 0 o positivo.

- Amplitud de Willison (WAMP): Representa la activación de los potenciales de acción de las unidades motoras y el nivel de contracción muscular [12]. Cuenta el número de veces que la amplitud de la señal supera un umbral predefinido. La ecuación (5) calcula:

$$WAMP = \sum_{i=1}^{N-1} f(|x_i - x_{i-1}|) \quad (5)$$

$$f(x) = \begin{cases} 1, & \text{if } x > \text{threshold} \\ 0, & \text{otherwise} \end{cases}$$

, donde el umbral definido fue de 0.05.

- Frecuencia Media (MNF): Calculado como la sumatoria del producto del espectro de potencia EMG y la frecuencia, dividida por la suma total de la intensidad del espectro [13]. La ecuación (6) calcula:

$$MNF = \frac{\sum_{i=1}^N \sum f_j P_j}{\sum_{i=1}^N \sum P_j} \quad (6)$$

- Frecuencia Mediana (MDF): Representa la frecuencia en que el espectro es dividido en dos regiones con igual amplitud. La ecuación (7) calcula:

$$MDF = \frac{1}{2} \sum_{i=1}^N P_j \quad (7)$$

- Frecuencia Pico (PKF): Representa la frecuencia a la que se produce la máxima potencia. La ecuación (8) calcula:

$$PKF = \max(P_j), j = 1, \dots, N \quad (8)$$

b) Generación de espectrogramas para DL: Cada registro de EMG se transforma del dominio temporal al dominio tiempo-frecuencia mediante la Transformada Rápida de Fourier de Tiempo Corto (STFT), una extensión de la DFT que aplica una ventana deslizante $w[n]$ de longitud fija sobre la señal. Matemáticamente, para cada canal obtenemos la siguiente ecuación (9) :

$$STFT\{x[n]\} = X(m, \omega) = \sum_{n=-\infty}^{\infty} x[n]w[n-m]e^{-j\omega n} \quad (9)$$

, donde $n = 256$ es el tamaño de ventana. El resultado obtenido es un espectrograma, un mapa de energía que muestra qué frecuencias están presentes y en qué instante aparecen. Esto es crucial porque las señales EMG son no estacionarias, su contenido espectral cambia bruscamente cuando el músculo se activa o se relaja. Asumir estacionariedad sólo dentro de

cada ventana corta permite capturar esa dinámica y ver cómo la energía migra entre bandas a lo largo del tiempo.

Los espectrogramas de todos los canales se apilan para formar un tensor. Este tensor 2-D es equivalente a una imagen multicanal, formato ideal para alimentar la 2D-CNN sin modificaciones adicionales.

D. Modelos de ML

En ambos casos, los modelos contemplaron garantizar la reproducibilidad de los experimentos, y se estableció una semilla aleatoria fija (`random_state=42`) en todos los procesos estocásticos.

a) Logistic Regression (LR): Para la implementación del modelo de LR en el presente estudio, se adoptó una estrategia de optimización de hiperparámetros mediante búsqueda exhaustiva por GridSearchCV, con validación cruzada estratificada de 5 "folds", lo que garantiza una evaluación robusta del rendimiento del modelo y reduce el riesgo de sobreajuste. El espacio de búsqueda de hiperparámetros incluyó el parámetro de regularización C, el cual controla la fuerza de la regularización con valores explorados en escala logarítmica [0.001, 0.01, 0.1, 1, 10, 100]. Adicionalmente, se evaluaron diferentes tipos de penalización: L1 (Lasso), L2 (Ridge) y Elastic Net, cada una con distintas propiedades para el control de la complejidad del modelo y la selección de características. Los parámetros adicionales optimizados incluyeron el número máximo de iteraciones del algoritmo de optimización como 1000 y 2000 iteraciones, para asegurar la convergencia del modelo, y la estrategia de clasificación multiclase, comparando los enfoques one-vs-rest (OvR) y multinomial.

b) Linear Support Vector Classifier (SVC): Dentro de la familia de modelos de Máquinas de Vectores de Soporte (SVM), el modelo Linear SVC implementa una versión optimizada de SVM para clasificación con kernel lineal, siendo particularmente eficiente para conjuntos de datos de alta dimensionalidad donde el número de características es superior al número de muestras, como es en nuestro caso. Linear SVC construye un hiperplano de separación óptimo en el espacio de características original, y utiliza la librería "liblinear", que proporciona una implementación más eficiente para problemas de clasificación lineal, especialmente cuando se trata de conjuntos de datos con un gran número de características.

Para la optimización de hiperparámetros del modelo Linear SVC, se empleó la estrategia de búsqueda aleatoria denominada RandomizedSearchCV con validación cruzada de 3 "folds". Esta aproximación fue seleccionada debido a su eficiencia computacional en comparación con la búsqueda exhaustiva, permitiendo explorar un espacio de parámetros amplio con un número limitado de iteraciones igual a 15. El espacio de búsqueda incluyó el parámetro de regularización C con valores [0.01, 0.1, 1, 10], que controla el balance entre la maximización del margen y la minimización del error de clasificación. Los hiperparámetros adicionales optimizados comprendieron el tipo de penalización, sea L1 y L2. Se evaluaron también diferentes funciones de pérdida: 'hinge' (pérdida estándar de SVM) y 'squared_hinge' (versión cuadrática que




Fig. 1. Matriz de confusión de modelo "Logistic Regression"

proporciona mayor estabilidad numérica). El parámetro 'dual' se fijó en False pues el número de muestras supera al número de características, para mejorar la eficiencia computacional. El número máximo de iteraciones se estableció en el rango [1000, 2000] para garantizar la convergencia, y se utilizó la estrategia de clasificación multiclase one-vs-rest (OvR), que es la implementación por defecto de Linear SVC.

E. Modelos de DL

a) *Arquitectura*: La red se basa en un único bloque convolucional compuesto por las siguientes capas:

- Convolution2D: Extrae características espaciales y lo convierte en una información de entrada bidimensional.
- BatchNorm: Se normaliza la salida de la convolución para acelerar el entrenamiento.
- ReLu: Para realizar una rectificación lineal en el vector de entrada de la red neuronal de la capa superior e introducir no linealidades al modelo
- MaxPool2D: Se reduce la dimensión espacial de las características y se conservan las más relevantes

TABLE I
COMPARACIÓN DE LOS PARÁMETROS DE RENDIMIENTO DE LOS DISTINTOS MODELOS

Modelo empleado	Parámetro de rendimiento			
	Accuracy	Precision	Recall	F1-score
Linear SVC	0.5559	0.5486	0.5587	0.5483
Logistic Regression	0.6048	0.6053	0.6073	0.6042
CNN	0.5266	0.5161	0.5153	0.5055

- Flatten: Se transforma la entrada multidimensional (el mapa de activación) en un vector unidimensional
- Linear: Realiza la clasificación final de las clases.

b) *Configuración*: Para el entrenamiento se usó el optimizador "Adam", una técnica muy empleada para tareas de este tipo de aprendizaje profundo por su eficiencia computacional. Asimismo, se usó una tasa de aprendizaje inicial de 1e-3 (learning rate = 1e-3) y se aplicó una regularización L2 de 1e-4 (weight_decay = 1e-4) para reducir el sobreajuste.

En adición, la función de pérdida aplicada fue "Cross-Entropy Loss", una función útil para clasificaciones de múltiples clases. Del mismo modo, se utilizó un tamaño de lote de 32 muestras (batch_size = 32) y, como scheduler de tasa de aprendizaje se empleó el ReduceLROnPlateau con un umbral de paciencia igual a 5.

F. Entrenamiento y validación

Para garantizar la consistencia metodológica y facilitar la comparación entre modelos, todos los algoritmos implementados (Regresión Logística, Linear SVC y CNN) fueron evaluados utilizando las mismas cuatro métricas de rendimiento: exactitud (accuracy), precisión (precision), sensibilidad (recall) y F1-score. Estas métricas fueron seleccionadas por su interpretabilidad directa y relevancia para el problema de clasificación multiclase planteado. La exactitud permite observar la proporción de las predicciones correctas en base al total del número de muestras evaluadas. Para complementar ello, se usó conjuntamente la precisión y el recall. Estas dos métricas miden la capacidad del modelo para clasificar los verdaderos positivos entre el conjunto total de predicciones. Teniendo estas dos métricas, finalmente, el F1-score permite equilibrar ambas métricas para evitar que las clases contribuyan de forma desproporcionada; esto porque se trata de un dataset demasiado robusto. Durante el proceso de optimización de hiperparámetros, se empleó la exactitud como métrica principal de evaluación en la validación cruzada para los modelos de aprendizaje automático tradicional. Para optimizar el tiempo de cómputo, se implementó paralelización (n_jobs=-1) aprovechando todos los núcleos de procesamiento disponibles.

Cada modelo fue entrenado con su configuración de parámetros que maximizó el rendimiento. Posteriormente, todos los modelos fueron evaluados en el conjunto de prueba independiente utilizando las cuatro métricas establecidas, obteniendo así una estimación imparcial de su capacidad de generalización y permitiendo una comparación directa entre las diferentes aproximaciones metodológicas implementadas.

III. RESULTADOS Y DISCUSIÓN

A. Comparación de rendimiento de los modelos

Los resultados obtenidos de la evaluación de los tres modelos implementados se presentan de manera comparativa en la Tabla 1, donde se detallan las métricas de rendimiento fundamentales para cada algoritmo desarrollado. Esta comparación permite identificar las fortalezas y limitaciones de cada modelo en el contexto del problema de clasificación

planteado, proporcionando una base empírica para la selección del modelo más adecuado.

La evaluación se realizó utilizando métricas estándar de clasificación que incluyen exactitud (accuracy), precisión (precision), sensibilidad o recall, especificidad, y la medida F1 (F1-score). Estas métricas fueron calculadas sobre el conjunto de prueba independiente para garantizar una evaluación imparcial del rendimiento de cada modelo. Adicionalmente, se incluyeron métricas macro y micro promediadas para proporcionar una perspectiva integral del rendimiento en el contexto de clasificación multiclase.

Los resultados revelan diferencias significativas en el rendimiento entre los modelos de aprendizaje automático tradicional (Regresión Logística y Linear SVC) y el modelo de aprendizaje profundo (CNN). Estas diferencias pueden atribuirse a las distintas capacidades de cada aproximación para capturar patrones complejos y no lineales en los datos, así como a su sensibilidad a la dimensionalidad y estructura del conjunto de datos utilizado.

A partir de la Tabla 1, se muestra que el modelo de Regresión Logística obtuvo el mejor rendimiento en comparación con los demás modelos, con una exactitud de 0.6048, una precisión de 0.6053, sensibilidad igual a 0.6073 y una puntuación de F1-Score igual a 0.6042. Esta superioridad puede deberse principalmente a su capacidad del modelo para manejar la alta dimensionalidad de las características extraídas. Asimismo, cabe señalar que entre los modelos de aprendizaje automático tradicional se seleccionaron diversos hiperparámetros optimizados con GridSearchCV, lo cual ayuda a mejorar significativamente el desempeño del modelo. Sin embargo, en el caso del SVC, el rendimiento inferior puede deberse a su menor flexibilidad para ajustarse al dataset.

En cuanto al modelo del CNN, el bajo rendimiento fue inesperado. Esto porque en los resultados del entrenamiento, se pudo observar que el valor de la exactitud, en las épocas iniciales, fue bajo; sin embargo en las épocas finales se alcanzó un puntaje por encima de 0.9. Esta característica mostraba que el modelo no se quedaba estancado, sino que está aprendiendo de manera progresiva y sostenida. Lo cual no se evidenció con los datos del testeo y se obtuvo un rendimiento demasiado bajo; revelando problemas de sobreajuste o limitaciones del modelo para generalizar los patrones de los gestos; lo cual también puede deberse a la complejidad inherente por el tamaño del dataset.

Ante ello, se muestra solo las matrices de confusión del modelo de Regresión Logística en la “Fig. ??”, proporcionando información detallada sobre los patrones de aciertos y errores de clasificación. El análisis de la diagonal principal evalúa la precisión individual por clase, mientras que los elementos fuera de la diagonal revelan los tipos de errores más frecuentes.

IV. CONCLUSIONES

En el estudio se realizó una evaluación comparativa entre dos modelos tradicionales de machine learning como son el modelo de Regresión Logística y el Linear SVC y un

modelo de deep learning como el CNN, esto en el contexto de reconocimiento de gestos para el control de prótesis mioeléctricas utilizando señales electromiográficas de alta densidad (HD-sEMG).

Concluyendo así que los modelos de machine learning tradicional mostraron un desempeño superior al modelo de deep learning en este contexto específico, destacando el modelo de Regresión Logística con un rendimiento del 60.48% en accuracy. Destacando la importancia de una selección cuidadosa y optimización de características para aplicaciones prácticas en control protésico. Adicionalmente, se identificaron limitaciones claras en cuanto al modelo de CNN debido al sobreajuste frente a la alta variabilidad intra e inter-sujeto presente en el dataset utilizado.

Como recomendación en investigaciones futuras esta el considerar métodos avanzados de reducción de dimensionalidad y técnicas de aumento de datos para mejorar la capacidad de generalización de redes neuronales profundas.

En resumen, los hallazgos presentados dan una base sólida para futuras investigaciones orientadas al desarrollo preciso y confiables para el control de prótesis mioeléctricas, enfatizando la necesidad de metodologías híbridas que integren la robustez del machine learning tradicional con el potencial adaptativo de los métodos de deep learning.

REFERENCES

- [1] “Amputaciones y desarticulaciones de los miembros: miembro superior”, *EMC - Téc. Quirúrgicas - Ortop. Traumatol.*, vol. 13, núm. 4, pp. 1–18, dic. 2021, doi: 10.1016/S2211-033X(21)45768-3.
- [2] J. L. Vara Mayo, “Evaluación de funcionalidad y calidad de vida en personas con amputación de miembro superior usuarias y no usuarias de prótesis”, bachelor thesis, 2020. Consultado: el 14 de mayo de 2025. [En línea]. Disponible en: <https://ruc.udc.es/dspace/handle/2183/27071>
- [3] W. Nishino, Y. Yamanoi, Y. Sakuma, y R. Kato, “Development of a myoelectric prosthesis simulator using augmented reality”, en *2017 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, Banff, AB: IEEE, oct. 2017, pp. 1046–1051. doi: 10.1109/SMC.2017.8122749.
- [4] A. Liu, M. L. Elwin, y Z. A. Wright, “Semi-supervised adaptation of upper-limb myoelectric pattern recognition prosthesis control through virtual gameplay”, en *2023 11th International IEEE/EMBS Conference on Neural Engineering (NER)*, Baltimore, MD, USA: IEEE, abr. 2023, pp. 01–05. doi: 10.1109/NER52421.2023.10123898.
- [5] “Decoding the neural drive to muscles from the surface electromyogram”, *Clin. Neurophysiol.*, vol. 121, núm. 10, pp. 1616–1623, oct. 2010, doi: 10.1016/j.clinph.2009.10.040.
- [6] “Hand gesture recognition based on motor unit spike trains decoded from high-density electromyography”, *Biomed. Signal Process. Control*, vol. 55, p. 101637, ene. 2020, doi: 10.1016/j.bspc.2019.101637.
- [7] X. Jiang et al., “Open Access Dataset, Toolbox and Benchmark Processing Results of High-Density Surface Electromyogram Recordings” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 29, pp. 1035–1046, 2021, doi: <https://doi.org/10.1109/tnsre.2021.3082551>.
- [8] Y.-S. Kim, M. K. Kim, N. Fu, J. Liu, J. Wang, and Jelena Srebric, “Investigating the Impact of Data Normalization Methods on Predicting Electricity Consumption in a Building Using different Artificial Neural Network Models.” *Sustainable Cities and Society*, pp. 105570–105570, Jun. 2024, doi: <https://doi.org/10.1016/j.scs.2024.105570>.
- [9] C. L. Kok, C. K. Ho, F. K. Tan, and Y. Y. Koh, “Machine Learning-Based Feature Extraction and Classification of EMG Signals for Intuitive Prosthetic Control,” *Applied Sciences*, vol. 14, no. 13, pp. 5784–5784, Jul. 2024, doi: <https://doi.org/10.3390/app14135784>.
- [10] S. Abbaspour, M. Lindén, H. Gholamhosseini, A. Naber, and M. Ortiz-Catalan, “Evaluation of surface EMG-based recognition algorithms for decoding hand movements,” *Medical & Biological Engineering & Computing*, vol. 58, no. 1, pp. 83–100, Nov. 2019, doi: <https://doi.org/10.1007/s11517-019-02073-z>.

- [11] I. Mohd Khairuddin, S. N. Sidek, A. P.P. Abdul Majeed, M. A. Mohd Razman, A. Ahmad Puzi, and H. Md Yusof, "The classification of movement intention through machine learning models: the identification of significant time-domain EMG features," *PeerJ Computer Science*, vol. 7, p. e379, Feb. 2021, doi: <https://doi.org/10.7717/peerj-cs.379>.
- [12] V. M. Gallón, S. M. Vélez, J. Ramírez, and F. Bolaños, "Comparison of machine learning algorithms and feature extraction techniques for the automatic detection of surface EMG activation timing," *Biomedical Signal Processing and Control*, vol. 94, p. 106266, Aug. 2024, doi: <https://doi.org/10.1016/j.bspc.2024.106266>.
- [13] Mojisola Grace Asogbon et al., "Appropriate Feature Set and Window Parameters Selection for Efficient Motion Intent Characterization towards Intelligently Smart EMG-PR System," *Symmetry*, vol. 12, no. 10, pp. 1710–1710, Oct. 2020, doi: <https://doi.org/10.3390/sym12101710>.